

TECH CHALLENGE · FASE 2

Classificando a Qualidade de Vinhos com Machine Learning

Um modelo preditivo que prevê a qualidade de um vinho a partir de suas características físico-químicas — apoiando enólogos e produtores na tomada de decisão.

Wine Quality Dataset · Análise Exploratória & Modelagem Preditiva



A indústria vitivinícola tem grande relevância econômica e cultural. Tradicionalmente, a qualidade de um vinho é avaliada por especialistas através de análises sensoriais (aroma, sabor, acidez e equilíbrio).

Esse processo, porém, é subjetivo, demorado e depende da experiência do avaliador. Com ciência de dados e aprendizado de máquina, é possível usar dados físico-químicos da produção para prever a qualidade final e padronizá-la.



Avaliação Tradicional

Sensorial e humana — precisa, mas subjetiva, lenta e difícil de padronizar.



Abordagem Data-Driven

Modelos aprendem padrões físico-químicos e apoiam decisões de forma objetiva e escalável.

META DO PROJETO **Objetivo**

Desenvolver um modelo de classificação capaz de prever a qualidade de um vinho a partir de suas características físico-químicas. Para simplificar o problema, a nota de qualidade foi transformada em uma variável binária:



ALTA QUALIDADE

Nota ≥ 7

Vinhos de destaque



BAIXA / MÉDIA QUALIDADE

Nota < 7

Demais amostras

O CONJUNTO DE DADOS — WINE QUALITY DATASET

1.143

Amostras de vinho

14

Atributos analisados

0

Valores ausentes


159

Vinhos de alta qualidade




COMO CHEGAMOS LÁ

A Jornada da Análise




Compreensão do Problema

Definir o objetivo e o que significa
um vinho de alta qualidade.




Análise Exploratória

Revelar padrões, tendências e
inconsistências nas amostras.



Pré- processamento

Organizar e enriquecer os dados
para a modelagem.




Modelagem & Avaliação

Testar diferentes modelos e
selecionar o mais confiável.

Uma pipeline completa de Ciência de Dados: da compreensão do negócio até a interpretação dos resultados.



Distribuição das Notas de Qualidade




O QUE OS DADOS REVELAM

- ✓ As notas concentram-se fortemente em 5 e 6 na grande maioria das amostras.
- ✓ Não há notas abaixo de 3 nem acima de 8.
- ✓ Apenas uma pequena parcela é de alta qualidade (nota ≥ 7).

Ponto de atenção: vinhos excepcionais são raros, reconhecê-los é o principal desafio.



Distribuição das Variáveis (1/2)



Como cada característica se comporta

Analizamos a distribuição das 14 características físico-químicas medidas em cada vinho.



Comportamentos distintos

Algumas características se concentram em valores baixos, com poucos vinhos em níveis elevados.




Escalas diferentes

As características são medidas em faixas muito distintas, por isso os dados são padronizados antes da modelagem.



Distribuição das Variáveis (2/2)



Álcool, sulfatos e a nota final



Base confiável

1.143 vinhos analisados, todos com dados completos, sem informações faltantes.




Poucos vinhos premium

Confirma que os vinhos de alta qualidade são minoria na base analisada.



Detecção de Outliers · Boxplots (1/2)



Identificando valores extremos

Esta visão destaca medições atípicas (valores muito acima ou abaixo do comum) em cada característica do vinho.



Presença generalizada

Várias características apresentam medições atípicas, sobretudo açúcar residual e cloretos.



Padrão recorrente

As medições atípicas se concentram nos valores mais altos, confirmando o padrão dos dados.



Detecção de Outliers · Boxplots (2/2)

Como tratamos os dados atípicos

Optamos por testar os modelos com e sem essas medições atípica, por três motivos:



São variações reais

Na produção de vinho, valores extremos costumam refletir lotes reais, não erros de medição.




Modelos resistentes

Os modelos escolhidos lidam bem com valores atípicos, sem grandes distorções.




Base enxuta

Só 159 vinhos são de alta qualidade, dados encolheria ainda mais a base.





Correlação entre as Variáveis



O que mais influencia a qualidade

MELHORAM A QUALIDADE

- ↑ Álcool **+0,40**
- ↑ Ácido cítrico **+0,25**
- ↑ Sulfatos **+0,21**

PIORAM A QUALIDADE


- ↓ Acidez volátil **-0,30**
- ↓ Densidade **-0,15**
- ↓ Dióxido enxofre total **-0,11**

O teor alcoólico é o fator físico-químico mais associado a vinhos de alta qualidade.



Matriz de Confusão dos Modelos

Comparação das Matrizes de Confusão dos Modelos



Lendo os acertos e erros

Cada grade mostra os acertos e os erros de um modelo ao separar vinhos de alta e baixa qualidade.



O modelo campeão se destaca

O Random Forest concentra a maioria dos acertos, a melhor separação entre as categorias.



O desafio dos vinhos premium

Acertar os vinhos de alta qualidade, que são minoria, é a parte mais difícil.



Equilíbrio entre os erros


Cada modelo equilibra de forma diferente os dois tipos de erro possíveis.



RESULTADOS · 02

Comparativo de Desempenho dos Modelos

Melhor variante de cada modelo · valores em %



MODELO VENCEDOR

Random Forest

+ Variáveis Novas, sem Outliers

93,24% acurácia

0,73

F1-Score

0,76

Precisão

0,70


Recall

A Regressão Logística ficou atrás (acurácia ~79–83%), sinalizando que a relação nos dados é não-linear, favorecendo modelos baseados em árvores.




INTERPRETAÇÃO

Discussão dos Resultados




Random Forest domina

Superioridade consistente em quase todas as métricas, a não-linearidade dos dados favorece árvores em vez de modelos lineares.




Engenharia de atributos

Efeito depende do algoritmo: refinou a Decision Tree (F1 0,56 → 0,58) e tornou a Random Forest mais criteriosa (mais precisão, menos recall).



Limpar os dados fez diferença

O maior salto de qualidade veio da limpeza dos outliers: melhor recall da Regressão Logística (0,78) e maior acurácia da Decision Tree (88,9%).



Implicações para a produção

Monitorar teor alcoólico, acidez volátil e sulfatos pode orientar ajustes no processo e padronizar a qualidade.

CONCLUSÃO

Da uva ao dado: prevendo a qualidade com confiança



Melhor solução

Nosso modelo (Random Forest) identifica corretamente mais de 9 em cada 10 vinhos: 93% de assertividade.



Fatores-chave da qualidade

Teor alcoólico, acidez volátil e sulfatos são os atributos mais determinantes.



Valor para o negócio

Modelos preditivos apoiam enólogos na padronização da qualidade e no ajuste do processo produtivo.





CONCLUSÃO LINKS



Github

<https://github.com/rodrigoscailoni/fase2/blob/main/wine-quality-classification/notebooks/exploracao.ipynb>



Vídeo

Link

OBRIGADO!

INTEGRANTES DO GRUPO:

Adrielle Dâmaris Leandro dos Santos
adrielledleandro@gmail.com

Vitor Lobo de Oliveira
vitorlobo383@gmail.com

Brandon Moura Bispo da Silva
brandon.bispo908@gmail.com

Rodrigo Scalioni Ribeiro
rodrigoscioni@hotmail.com

